Методы оптимизации (КТ'26)
Лабораторная работа 5

Задача регрессии

5.1 Постановка задачи 1
5.2 Модели регрессии 1
5.3 Функции потерь 1
5.4 Оптимизаторы 2
5.5 Рекомендуемая схема экспериментов 2
5.6 Рекомендации 3
5.7 Критерии оценивания 4

5.1 Постановка задачи

В работе необходимо исследовать задачу восстановления регрессионной зависимости по зашумленным данным. Данные генерируются самостоятельно на основе аналитических функций.
Сгенерировать два набора данных:

1. почти линейная зависимость;
2. сильно нелинейная зависимость.

Для каждой задачи необходимо взять не менее 100 точек и добавить нормально распределенный шум:

$$y_i = f_{\text{true}}(x_i) + \xi_i, \qquad \xi_i \sim \mathcal{N}(0, \sigma^2).$$

Истинная зависимость $f_{\text{true}}(x)$, дисперсия шума и диапазон значений x должны быть явно указаны в отчете.

5.2 Модели регрессии

Рассмотреть:

1. линейную регрессию;
2. полиномиальную регрессию.

Для полиномиальной регрессии необходимо исследовать несколько степеней полинома. Минимальный набор: степени 2, 3, 4 и 5. Для линейной регрессии считать степень полинома равной 1.

5.3 Функции потерь

Для каждой модели регрессии рассмотреть эмпирический риск

$$Q(w) = \frac{1}{m} \sum_{i=1}^{m} \left(\hat{y}(x_i, w) - y_i\right)^2$$

и четыре варианта функции потерь:

1. без регуляризации;
2. с L1-регуляризацией;
3. с L2-регуляризацией;
4. с Elastic Net-регуляризацией.

Регуляризованные функции можно задать в виде

$$L(w) = Q(w) + \lambda_1 \|w\|_1 + \lambda_2 \|w\|_2^2.$$

Для свободного коэффициента можно не применять регуляризацию, если это явно указано в отчете.

5.4 Оптимизаторы

Реализовать:

1. аналитическое решение задачи линейной регрессии через оценки средних для одномерного случая;
2. стохастический градиентный спуск;
3. mini-batch градиентный спуск;
4. метод Гаусса–Ньютона;
5. метод Гаусса–Ньютона с регуляризацией Левенберга–Марквардта.

Для каждого метода необходимо сохранять историю значений функции потерь, эмпирического риска и регуляризационных слагаемых. Для SGD и mini-batch методов также необходимо фиксировать размер batch, число эпох и правило выбора шага.

5.5 Рекомендуемая схема экспериментов

Чтобы объем работы оставался разумным, не требуется запускать каждый метод на всех возможных сочетаниях модели, степени полинома и регуляризации. Обязательная схема экспериментов приведена ниже.

1. Для каждой из двух регрессионных задач построить базовые модели без регуляризации.
   - Рассмотреть линейную регрессию и несколько полиномиальных регрессий.
   - Обучить модели аналитическим решением, если оно применимо, SGD, mini-batch, методом Гаусса–Ньютона и методом Левенберга–Марквардта.
   - Построить график истинной зависимости, зашумленных точек и предсказанной регрессионной функции для каждой пары "задача + метод".
   - Построить динамику loss для каждого итерационного метода.
   - Сравнить итоговые значения loss и качество аппроксимации.
2. Исследовать влияние размера batch.
   - Выбрать одну регрессионную задачу и одну модель, например нелинейную задачу и полиномиальную регрессию степени 5.

- Для mini-batch метода рассмотреть несколько размеров batch: например 1, 4, 8, 16, 32, 64, m.
- Для каждого размера batch построить динамику loss по эпохам и по числу вычислений градиента.
- Сравнить размеры batch по скорости сходимости, стабильности траектории loss и вычислительной эффективности.
- Сделать вывод о том, какой размер batch оказался наиболее удачным для выбранной задачи и почему.

3. Исследовать регуляризацию.

- Выбрать одну задачу, на которой заметно переобучение без регуляризации. Рекомендуется использовать нелинейную задачу и полиномиальную регрессию высокой степени.
- Для L1, L2 и Elastic Net рассмотреть несколько значений параметров регуляризации.
- Для каждого варианта построить графики динамики полного loss, эмпирического риска и регуляризационных слагаемых.
- Построить графики истинной зависимости, зашумленных точек и предсказаний моделей до регуляризации и после регуляризации.
- Сравнить коэффициенты моделей по абсолютным значениям до регуляризации и после регуляризации.
- Сделать вывод о влиянии разных типов регуляризации на качество восстановления зависимости и на структуру коэффициентов.

4. Сравнить методы оптимизации.

- Для выбранных постановок представить таблицу итоговых значений loss, числа итераций или эпох, числа вычислений градиента и времени работы.
- Отдельно сравнить Гаусса–Ньютона и Левенберга–Марквардта на нелинейной или плохо обусловленной постановке.
- Описать случаи, когда метод сходится медленно, расходится или чувствителен к начальному приближению.

5.6 Рекомендации

Для почти линейной зависимости можно взять функцию вида

$$f_{\text{true}}(x) = ax + b + 0.1\sin(cx),$$

а для сильно нелинейной зависимости — комбинацию синуса, полиномиального тренда и локального пика. Допускается выбрать другие аналитические функции, если они явно описаны в отчете.

Для полиномиальной регрессии рекомендуется нормировать входной признак x перед построением степеней, чтобы уменьшить плохую обусловленность задачи.

Для L1-регуляризации допускается использовать сглаженную аппроксимацию модуля.

Для метода Левенберга–Марквардта необходимо реализовать правило изменения параметра регуляризации: увеличивать его при неудачном шаге и уменьшать при успешном шаге.

Не обязательны, но приветствуются ООП-архитектуры, единый интерфейс моделей и оптимизаторов, декораторы для подсчета вычислений и сохранение результатов экспериментов в табличном формате.

Обязательно использование векторизованных операций *NumPy* там, где это допустимо.

5.7 Критерии оценивания

1. Код и отчет. Оценивается работоспособность и качество кода, корректность генерации данных, реализация методов оптимизации, полнота графиков и таблиц, анализ batch size, анализ регуляризации и сравнение коэффициентов.

2. Защита: Оценивается понимание задачи регрессии, функций потерь, регуляризации, стохастических методов, методов Гаусса–Ньютона и Левенберга–Марквардта, а также умение объяснять полученные результаты.

Каждый критерий оценивается максимально в 5 баллов.
Итого максимальный балл за лабораторную работу: 10 баллов.